

UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ
CAMPUS APUCARANA
CURSO DE ENGENHARIA DE COMPUTAÇÃO

RAFAEL ZAUPA WATANABE

SEGMENTAÇÃO DE FERIDAS DIABÉTICAS USANDO PROCESSAMENTO DIGITAL DE IMAGENS E DEEP LEARNING

Relatório apresentado à disciplina de Processamento Digital de Imagens, do Curso de Engenharia de Computação da Universidade Tecnológica Federal do Paraná, Campus Apucarana, como requisito parcial para avaliação do projeto final.

Professor Dr. Fabio Irigon

Apucarana

2026

1 Introdução

Este projeto apresenta um pipeline de Processamento Digital de Imagens aplicado à análise de imagens de feridas relacionadas ao pé diabético. O objetivo é identificar automaticamente a região provável da ferida em uma imagem e, em seguida, destacar visualmente diferentes tecidos aparentes presentes na lesão.

O sistema foi desenvolvido para execução no Google Colab, utilizando Python, TensorFlow/Keras, OpenCV, NumPy, Pandas e Matplotlib.

2 Dataset

Foi utilizado o dataset *Diabetic Foot Ulcer*, disponível na plataforma Kaggle, composto por imagens de pés diabéticos e patches organizados em duas classes principais:

- `Abnormal (Ulcer)`: patches contendo regiões de ferida ou úlcera;
- `Normal (Healthy skin)`: patches contendo pele saudável.

O dataset pode ser acessado em:

<https://www.kaggle.com/datasets/laithjj/diabetic-foot-ulcer-dfu>

Como o dataset não possui máscaras pixel a pixel para segmentação semântica, não foi possível treinar diretamente um modelo do tipo U-Net ou DeepLab para segmentação supervisionada. Sendo assim, foi adotada uma abordagem híbrida, combinando Deep Learning para classificação de patches e técnicas clássicas de Processamento Digital de Imagens para pós-processamento e classificação visual dos tecidos.

3 Pipeline

O pipeline final foi dividido nas seguintes etapas:

1. carregamento e extração do dataset;
2. preparação dos patches de treino e validação;
3. treinamento de um classificador binário;

4. aplicação do modelo em imagens completas por janela deslizante;
5. geração de um mapa de probabilidade da ferida;
6. criação de uma máscara binária da região provável da ferida;
7. pós-processamento morfológico da máscara;
8. classificação aproximada dos tecidos aparentes por cor;
9. visualização dos resultados.

Esse é o fluxo geral de funcionamento do código. Em duas etapas, o programa solicita entrada do usuário: no início, para o carregamento do dataset mencionado anteriormente; e ao final, para a utilização de uma imagem que o usuário deseja testar.

4 Classificação com Deep Learning

Para a etapa de classificação dos patches, foi utilizada a arquitetura MobileNetV2 com transferência de aprendizado. Essa escolha foi feita porque a MobileNetV2 é uma rede convolucional leve, eficiente e adequada para aplicações em ambientes com recursos limitados, como o Google Colab, além de ser compatível com possíveis aplicações futuras em dispositivos móveis.

A rede foi inicializada com pesos pré-treinados e adaptada para uma tarefa binária:

- classe 0: pele saudável;
- classe 1: ferida ou úlcera.

A saída do modelo é uma probabilidade entre 0 e 1, indicando a chance de um patch conter região de ferida. Foi utilizada a função de perda `binary_crossentropy`, adequada para classificação binária, e o otimizador Adam.

Também foi usada uma *seed* fixa para reduzir a aleatoriedade na divisão dos dados, inicialização das camadas treináveis e embaralhamento das imagens. Essa escolha contribui para maior reprodutibilidade dos resultados.

5 Segmentação aproximada da ferida

Como o dataset não fornece máscaras reais da ferida, a segmentação foi feita de forma aproximada. Para isso, o classificador treinado foi aplicado em imagens completas por meio de uma técnica de janela deslizante.

A imagem é percorrida por janelas de tamanho 224×224 pixels, compatíveis com a entrada da MobileNetV2. Em cada janela, o modelo estima a probabilidade de presença de ferida. As probabilidades obtidas são combinadas para formar um mapa de calor, no qual regiões mais claras indicam maior probabilidade de conter ferida.

Foi utilizado `stride=32` para melhorar a resolução espacial do mapa de probabilidade. Esse valor gera maior sobreposição entre as janelas e tende a produzir uma segmentação visualmente mais detalhada, embora aumente o tempo de processamento.

6 Pós-processamento da máscara

Após a geração do mapa de calor, foi aplicada uma etapa de pós-processamento para criar a máscara binária da ferida. As principais escolhas tomadas foram:

- suavização do mapa com filtro Gaussiano;
- limiarização geralmente com `threshold=0.80`;
- operações morfológicas de abertura e fechamento;
- remoção de componentes pequenos;
- manutenção da maior região conectada.

O valor de limiar escolhido é razoavelmente alto. Essa escolha foi feita após testes práticos, pois apresentou melhores resultados para o código atual, reduzindo a detecção excessiva de regiões que não pertencem à ferida.

7 Classificação dos tecidos aparentes

Após a obtenção da máscara da ferida, a classificação dos tecidos foi feita apenas dentro da região segmentada. Essa etapa não utiliza Deep Learning, mas sim regras baseadas em cor no espaço HSV e em características RGB.

As classes finais utilizadas foram:

- 0: fora da ferida;
- 1: escara ou necrose escura;
- 2: fibrina ou *slough*;
- 3: tecido de granulação;
- 4: epitelização;
- 5: maceração;
- 6: região incerta dentro da ferida.

A escara ou necrose foi associada a regiões muito escuras ou marrom-escuras. A fibrina ou *slough* foi associada a tons amarelados, bege ou creme. A granulação foi associada a regiões avermelhadas com predominância do canal vermelho. A epitelização foi associada a tons rosados claros próximos à borda da ferida. A maceração foi associada a regiões claras, pouco saturadas e esbranquiçadas, também próximas à borda.

A classe “incerto” foi incluída para evitar que pixels ambíguos fossem forçados a uma classe específica. Essa escolha torna o resultado mais cauteloso, especialmente considerando as variações de iluminação, foco, posição, cor de pele e qualidade das imagens.

8 Limitações

A principal limitação do projeto é a ausência de máscaras pixel a pixel no dataset utilizado. Por isso, a segmentação da ferida não é uma segmentação supervisionada real, mas uma aproximação gerada a partir de um classificador de patches.

Além disso, a classificação dos tecidos aparentes depende fortemente da cor da imagem. Assim, o resultado pode ser afetado por fatores como:

- iluminação inadequada;
- sombras;
- uso de flash;

- baixa resolução;
- pele com diferentes tonalidades;
- presença de curativos;
- fundo parecido com a pele;
- imagens desfocadas.

O sistema não possui finalidade diagnóstica e não deve ser usado para tomada de decisão médica. Trata-se de uma aplicação acadêmica dos conceitos aprendidos em Processamento Digital de Imagens, com auxílio de técnicas de Deep Learning.

9 Conclusão

O projeto demonstrou a viabilidade de combinar técnicas de Deep Learning e Processamento Digital de Imagens para análise aproximada de feridas diabéticas. A MobileNetV2 foi utilizada para identificar regiões prováveis de ferida em patches, enquanto a técnica de janela deslizante permitiu transformar essa classificação em uma máscara aproximada sobre a imagem completa.

A etapa de pós-processamento morfológico melhorou a qualidade da máscara, reduzindo ruídos e falsos positivos. Por fim, a classificação por cor em HSV permitiu destacar visualmente diferentes tecidos aparentes da ferida, como necrose, fibrina, granulação, epitelização e maceação. Ainda assim, nota-se a complexidade da classificação e os vários obstáculos a serem vencidos para a realização de um projeto viável para uso real.

Apesar das limitações, o pipeline atende ao objetivo acadêmico do projeto, fornecendo uma solução funcional, interpretável e executável no Google Colab.

Em futuras iterações, deseja-se melhorar a caracterização das classes e, se possível, obter ou criar máscaras feitas por especialistas para permitir uma segmentação supervisionada mais precisa.

10 Referências

KAGGLE. *Diabetic Foot Ulcer Dataset*. Disponível em: <https://www.kaggle.com/datasets/laithjj/diabetic-foot-ulcer-dfu>. Acesso em: 14 jun. 2026.

HOWARD, A. G. et al. *MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications*. arXiv, 2017.

SANDLER, M. et al. *MobileNetV2: Inverted Residuals and Linear Bottlenecks*. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018.

GONZALEZ, R. C.; WOODS, R. E. *Digital Image Processing*. 4. ed. Pearson, 2018.